

**IDENTIFIKASI TUMOR OTAK MENGGUNAKAN
MODEL DEEP LEARNING BERBASIS
VISION TRANSFORMER (VIT)**

SKRIPSI

Diajukan untuk memenuhi salah satu syarat mencapai derajat Sarjana
Program Studi S1 Informatika



disusun oleh

GILANG EKAYANDA

22.11.4833

Kepada

**FAKULTAS ILMU KOMPUTER
UNIVERSITAS AMIKOM YOGYAKARTA
YOGYAKARTA**

2025

**IDENTIFIKASI TUMOR OTAK MENGGUNAKAN
MODEL DEEP LEARNING BERBASIS
VISION TRANSFORMER (VIT)**

SKRIPSI

untuk memenuhi salah satu syarat mencapai derajat Sarjana
Program Studi S1 Informatika



disusun oleh

GILANG EKAYANDA

22.11.4833

Kepada

**FAKULTAS ILMU KOMPUTER
UNIVERSITAS AMIKOM YOGYAKARTA
YOGYAKARTA**

2025

HALAMAN PERSETUJUAN

SKRIPSI

IDENTIFIKASI TUMOR OTAK MENGGUNAKAN
MODEL DEEP LEARNING BERBASIS
VISION TRANSFORMER (VIT)

yang disusun dan diajukan oleh

GILANG EKAYANDA

22.11.4833

telah disetujui oleh Dosen Pembimbing Skripsi
pada tanggal <tanggal ujian>

Dosen Pembimbing,

Nama Dosen Pembimbing
NIK. 19030xxxx

HALAMAN PENGESAHAN
SKRIPSI
IDENTIFIKASI TUMOR OTAK MENGGUNAKAN
MODEL DEEP LEARNING BERBASIS
VISION TRANSFORMER (VIT)

yang disusun dan diajukan oleh

GILANG EKAYANDA

22.11.4833

Telah dipertahankan di depan Dewan Penguji
pada tanggal <tanggal ujian>

Susunan Dewan Penguji

Nama Penguji

Tanda Tangan

Nama dan Gelar Penguji 1
NIK. 190302xxx

Nama dan Gelar Penguji 2
NIK. 190302xxx

Nama dan Gelar Penguji 3
NIK. 190302xxx

Skripsi ini telah diterima sebagai salah satu persyaratan
untuk memperoleh gelar Sarjana Komputer
Tanggal < tanggal lulus ujian >

DEKAN FAKULTAS ILMU KOMPUTER

Prof. Dr. Kusrini, M.Kom.
NIK. 190302106

HALAMAN PERNYATAAN KEASLIAN SKRIPSI

Yang bertandatangan di bawah ini,

Nama mahasiswa : GILANG EKAYANDA
NIM : 22.11.4833

Menyatakan bahwa Skripsi dengan judul berikut:

IDENTIFIKASI TUMOR OTAK MENGGUNAKAN MODEL DEEP LEARNING BERBASIS VISION TRANSFORMER (VIT)

Dosen Pembimbing : Majid Rahardi, S.Kom., M.Eng.

1. Karya tulis ini adalah benar-benar ASLI dan BELUM PERNAH diajukan untuk mendapatkan gelar akademik, baik di Universitas AMIKOM Yogyakarta maupun di Perguruan Tinggi lainnya.
2. Karya tulis ini merupakan gagasan, rumusan dan penelitian SAYA sendiri, tanpa bantuan pihak lain kecuali arahan dari Dosen Pembimbing.
3. Dalam karya tulis ini tidak terdapat karya atau pendapat orang lain, kecuali secara tertulis dengan jelas dicantumkan sebagai acuan dalam naskah dengan disebutkan nama pengarang dan disebutkan dalam Daftar Pustaka pada karya tulis ini.
4. Perangkat lunak yang digunakan dalam penelitian ini sepenuhnya menjadi tanggung jawab SAYA, bukan tanggung jawab Universitas AMIKOM Yogyakarta.
5. Pernyataan ini SAYA buat dengan sesungguhnya, apabila di kemudian hari terdapat penyimpangan dan ketidakbenaran dalam pernyataan ini, maka SAYA bersedia menerima SANKSI AKADEMIK dengan pencabutan gelar yang sudah diperoleh, serta sanksi lainnya sesuai dengan norma yang berlaku di Perguruan Tinggi.

Yogyakarta, <tanggal lulus ujian skripsi>

Yang Menyatakan,

Meterai Asli
Rp 10.000,-

GILANG EKAYANDA

HALAMAN PERSEMBAHAN

(Bila ada) Halaman ini berisi kepada siapa skripsi dipersembahkan. Ditulis dengan singkat, resmi, sederhana, tidak terlalu banyak, serta tidak menjurus ke penulisan informal sehingga mengurangi sifat resmi laporan ilmiah.

KATA PENGANTAR

Bagian ini berisi pernyataan resmi yang ingin disampaikan oleh penulis kepada pihak lain, misalnya ucapan terima kasih kepada Dosen Pembimbing, Tim Dosen Penguji, dan semua pihak yang terkait dalam penyelesaian skripsi termasuk orang tua dan penyandang dana.

Nama harus ditulis secara lengkap termasuk gelar akademik dan harus dihindari ucapan terima kasih kepada pihak yang tidak terkait. Bahasa yang digunakan harus mengikuti kaidah bahasa Indonesia yang baku.

Bagian ini tidak perlu dituliskan hal-hal yang bersifat ilmiah. Kata Pengantar diakhiri dengan mencantumkan kota dan tanggal penulisan diikuti di bawahnya dengan **kata “Penulis” tanpa perlu menyebutkan nama dan tanda tangan.**

Yogyakarta, <tanggal bulan tahun>

Penulis

DAFTAR ISI

HALAMAN JUDUL	i
HALAMAN PERSETUJUAN	ii
HALAMAN PENGESAHAN.....	iii
HALAMAN PERNYATAAN KEASLIAN SKRIPSI.....	iv
HALAMAN PERSEMBAHAN	v
KATA PENGANTAR.....	vi
DAFTAR ISI.....	vii
DAFTAR TABEL	x
DAFTAR GAMBAR.....	xi
DAFTAR LAMPIRAN	xii
DAFTAR LAMBANG DAN SINGKATAN	xiii
DAFTAR ISTILAH	xiv
INTISARI	xvi
<i>ABSTRACT</i>	xvii
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Batasan Masalah	3
1.4 Tujuan Penelitian	4
1.5 Manfaat Penelitian	4
1.6 Sistematika Penulisan	5
BAB II TINJAUAN PUSTAKA	6
2.1 Studi Literatur	6
2.2 Dasar Teori.....	14
2.2.1 Citra Magnetic Resonance Imaging (MRI).....	14
2.2.2 Pengolahan Citra Digital.....	14
2.2.3 Deep Learning untuk Klasifikasi Citra	15
2.2.4 Arsitektur Transformer dan Self-Attention.....	15
2.2.5 Framework PyTorch	16

2.2.6 Metode Evaluasi.....	17
BAB III METODE PENELITIAN	19
3.1 Objek Penelitian.....	19
3.2 Alur Penelitian	19
3.2.1 Identifikasi Masalah.....	20
3.2.2 Studi Literatur	20
3.2.3 Pengumpulan Data	20
3.2.4 Data Preprocessing.....	20
3.2.5 Pemisahan Data (Training dan Testing).....	20
3.2.6 Modeling	21
3.2.7 Perbandingan Evaluasi Model	21
3.2.8 Deployment dan Analisis Performa Model.....	22
3.2.9 Analisis Hasil	22
3.3 Alat dan Bahan.....	22
BAB IV HASIL DAN PEMBAHASAN	24
4.1 Pengumpulan Data	24
4.2 Data Preprocessing.....	25
4.2.1 Definisi Transformasi dan Augmentasi	25
4.3 Pembagian Data (Train–Validation Split).....	26
4.4 Modeling	26
4.4.1 Lingkungan Eksperimen	28
4.5 Perbandingan Evaluasi Model	29
4.5.1 Grafik Loss vs Epoch.....	30
4.5.2 Confusion Matrix	31
4.5.3 Metrik Kinerja.....	32
4.5.4 Receiver Operating Characteristic (ROC) Curve.....	33
4.5.5 Hasil Evaluasi	35
4.6 Deployment dan Analisis Performa Model.....	35
4.6.1 Pembahasan.....	37
4.7 Analisis Hasil	37
4.7.1 Interpretasi Kelemahan & Keterbatasan	38

BAB V PENUTUP.....	39
5.1Kesimpulan	39
5.2Saran	39
REFERENSI.....	41
LAMPIRAN.....	43

DAFTAR TABEL

Tabel 2.1.Keaslian Penelitian	8
Tabel 4.1 Komposisi Dataset	24
Tabel 4.2 Transformasi dan Augmentasi yang dilakukan	25
Tabel 4.3 Pembagian Data	26
Tabel 4.4 Pengaturan Pelatihan	26
Tabel 4.5 Lingkungan Eksperimen	28

DAFTAR GAMBAR

Gambar 2.1. Mesin MRI	14
Gambar 2.2. Contoh Pra-pemrosesan Citra Digital MRI	15
Gambar 2.3. Arsitektur Transformer dan Self-Attention	16
Gambar 3.1 Alur Penelitian	19
Gambar 4.1 Visualisasi Train Vs Validation Loss Per Epoch	30
Gambar 4.2 Confusion Matrix	31
Gambar 4.3 Metrik Kinerja	32
Gambar 4.4 Evaluasi ROC AUC Score	34
Gambar 4.5 Tampilan Awal	35
Gambar 4.6 Tampilan Preview Gambar	36
Gambar 4.7 Tampilan Hasil Prediksi	36

DAFTAR LAMPIRAN

Lampiran 1. Profil obyek Penelitian	10
Lampiran 2. Dokumentasi Penelitian	11

DAFTAR LAMBANG DAN SINGKATAN

TP	True Positive: jumlah citra tumor yang benar terdeteksi sebagai tumor
TN	True Negative: jumlah citra sehat yang benar terdeteksi sebagai sehat
FP	False Positive: jumlah citra sehat yang keliru terdeteksi sebagai tumor
FN	False Negative: jumlah citra tumor yang keliru terdeteksi sebagai sehat
TPR	True Positive Rate (Recall): $TP \div (TP + FN)$
FPR	False Positive Rate: $FP \div (FP + TN)$
SSIM	Structural Similarity Index Measure: metrik kesamaan struktur citra
AUC–ROC	Area Under the Curve – Receiver Operating Characteristic: luas di bawah kurva ROC
η	Learning rate: laju pembaruan bobot pada setiap iterasi training
λ	Weight decay: koefisien regularisasi L2 pada optimizer
Singkatan	Keterangan
MRI	Magnetic Resonance Imaging
CNN	Convolutional Neural Network
GLCM	Gray Level Co-occurrence Matrix
SVM	Support Vector Machine
ViT	Vision Transformer
SSIM	Structural Similarity Index Measure
ROC	Receiver Operating Characteristic
AUC	Area Under the Curve
GPU	Graphics Processing Unit
MLP	Multi-Layer Perceptron
PyTorch	Python-based deep learning framework
AdamW	Adaptive Moment Estimation with Weight Decay

DAFTAR ISTILAH

Tumor Otak	Massa jaringan abnormal di otak yang dapat bersifat jinak (benign) atau ganas (malign), memengaruhi fungsi neurologis.
(MRI)	Teknik pencitraan medis non-invasif yang memanfaatkan medan magnet kuat dan gelombang radio untuk menghasilkan penampang jaringan lunak tubuh, termasuk otak.
Preprocessing	Tahapan awal pengolahan data citra sebelum pelatihan model, meliputi normalisasi intensitas, resizing, dan augmentasi untuk meningkatkan kualitas data.
Augmentasi	Teknik memperkaya variasi data citra (misalnya rotasi, flipping, zoom) untuk mencegah overfitting dan meningkatkan generalisasi model.
Patch	Sub-citra berukuran kecil (misalnya 16×16 piksel) hasil pemecahan citra utama, digunakan sebagai input token pada Vision Transformer.
Embedding	Representasi vektor berdimensi tetap (misalnya 768) yang merepresentasikan setiap patch citra dalam ruang fitur model.
Self-Attention	Mekanisme di Transformer yang memungkinkan setiap token (patch) untuk “memperhatikan” (attend) semua token lainnya dalam satu citra secara bersamaan.
Multi-Head Attention	Penerapan beberapa mekanisme self-attention paralel, sehingga model dapat menangkap berbagai pola hubungan antar-token dari sub-ruang yang berbeda.
Positional Encoding	Penambahan informasi posisi token/pixel ke dalam embedding, agar model Transformer mengenali urutan atau lokasi spasial meski memproses data secara paralel.

Epoch	Satu siklus penuh di mana seluruh dataset telah digunakan sekali untuk melatih model.
Batch Size	Jumlah sampel citra yang diproses sekaligus sebelum model melakukan update bobot dalam satu iterasi.
Learning Rate	Parameter yang mengatur besaran langkah pembaruan bobot model pada tiap iterasi optimisasi.
AdamW	Varian optimizer Adam yang menambahkan regularisasi L2 (weight decay) untuk mencegah bobot model menjadi terlalu besar.
Confusion Matrix	Tabel 2×2 yang merangkum hasil klasifikasi: True Positive, True Negative, False Positive, dan False Negative.
Precision	Rasio prediksi positif yang benar dari seluruh prediksi positif; mencerminkan tingkat kesalahan positif.
Recall (Sensitivitas)	Rasio deteksi positif yang benar dari seluruh kasus sebenarnya positif; mencerminkan kemampuan model menemukan semua kasus positif.
F1-Score	Rata-rata harmonis antara precision dan recall; mengukur keseimbangan keduanya.
AUC-ROC	Luas di bawah kurva Receiver Operating Characteristic; menggambarkan kemampuan model membedakan kelas positif dan negatif di berbagai threshold.
GPU	Graphics Processing Unit; perangkat keras akselerator komputasi paralel yang mempercepat proses pelatihan deep learning.

INTISARI

Penelitian ini membahas tantangan dalam deteksi dini tumor otak melalui analisis citra MRI yang selama ini masih bergantung pada interpretasi manual ahli radiologi sehingga memakan waktu, berisiko subjektivitas, dan menghambat penanganan cepat pasien. Tingginya angka kasus dan mortalitas tumor otak menuntut pengembangan sistem otomatis yang andal untuk mempercepat diagnosis dan meningkatkan akurasi pengambilan keputusan klinis.

Metode yang diusulkan memanfaatkan arsitektur Vision Transformer (ViT) yang diimplementasikan dalam framework PyTorch. Dataset “Brain MRI Images for Brain Tumor Detection” dari Kaggle dipra-processing melalui normalisasi intensitas, resizing menjadi 224×224 piksel, dan augmentasi dasar (rotasi, flipping). Citra kemudian dipecah menjadi patch 16×16 piksel dan diubah menjadi embedding berdimensi 768. Model ViT-Base/16 dilatih end-to-end menggunakan optimizer AdamW dengan hyperparameter yang dioptimalkan melalui validasi silang, serta dievaluasi menggunakan metrik akurasi, AUC–ROC, precision, recall, dan F1-score.

Hasil akhir menunjukkan model mencapai akurasi hampir sempurna (100%), AUC–ROC 0,9994, precision dan recall mendekati 1, serta false positive dan false negative yang sangat rendah. Kontribusi penelitian ini terletak pada penerapan mekanisme self-attention untuk mendeteksi pola spasial dan tekstur abnormal tanpa praproses kompleks, mempermudah integrasi dalam pipeline klinis, dan mempercepat interpretasi data MRI. Hasil ini bermanfaat bagi tenaga medis, pengembang aplikasi klinis, dan peneliti dalam pengembangan sistem deteksi tumor otak berbasis kecerdasan buatan.

Kata kunci: tumor otak, Vision Transformer, PyTorch, MRI, deteksi dini.

ABSTRACT

This study addresses the challenge of early brain tumor detection from MRI images, which traditionally relies on time-consuming manual interpretation by radiologists and is prone to subjectivity, thereby delaying patient treatment. The high incidence and mortality rates of brain tumors necessitate an automated, reliable diagnostic system to accelerate decision-making and improve clinical outcomes.

We propose a Vision Transformer (ViT) based approach implemented in PyTorch. The publicly available “Brain MRI Images for Brain Tumor Detection” dataset from Kaggle was preprocessed via intensity normalization, resizing to 224×224 pixels, and basic augmentation (rotation, flipping). Each image was partitioned into 16×16 -pixel patches and embedded into a 768-dimensional feature vector. A ViT-Base/16 model was trained end-to-end using the AdamW optimizer, with hyperparameters optimized through cross-validation, and evaluated on accuracy, AUC-ROC, precision, recall, and F1-score metrics.

The trained model achieved near-perfect performance 100% accuracy, 0.9994 AUC-ROC, and precision and recall close to 1 while maintaining minimal false positives and false negatives. This research demonstrates the effectiveness of self-attention mechanisms in capturing global spatial and textural abnormalities without complex preprocessing, facilitating clinical integration and expediting MRI interpretation. The results benefit medical practitioners, clinical application developers, and researchers in AI-based brain tumor detection.

Keyword: brain tumor, Vision Transformer, PyTorch, MRI, early detection.

BAB I

PENDAHULUAN

1.1 Latar Belakang

Pertumbuhan sel abnormal di otak yang menyebabkan tumor otak menjadikannya salah satu penyakit paling serius dan kompleks, serta menjadi perhatian besar dalam dunia kesehatan di berbagai negara [5], [8], [10]. Tingginya angka kasus dan mortalitas, seperti yang tercatat di Indonesia, menunjukkan urgensi untuk mengembangkan metode diagnosis yang lebih baik [5]. Deteksi dini dan akurat menjadi faktor krusial yang sangat memengaruhi keberhasilan pengobatan dan prognosis pasien [7], [10]. Dalam dunia klinis, Magnetic Resonance Imaging (MRI) sering digunakan sebagai metode utama untuk mendeteksi tumor otak karena kemampuannya memberikan visualisasi rinci dari struktur otak bagian dalam [2], [4]. Namun, proses interpretasi citra MRI secara manual oleh ahli radiologi memerlukan keahlian tinggi, memakan waktu, dan memiliki risiko subjektivitas atau kesalahan diagnosis [8], [10]. Keterbatasan ini mendorong kebutuhan mendesak untuk mengembangkan sistem deteksi otomatis yang dapat membantu tenaga medis dalam membuat keputusan yang lebih cepat dan akurat.

Perkembangan teknologi komputasi telah membuka jalan bagi berbagai metode untuk membantu analisis citra medis. Pada tahap awal, penelitian berfokus pada teknik pemrosesan citra konvensional untuk meningkatkan kualitas visual atau mengekstraksi fitur spesifik dari citra MRI. Metode seperti watershed dan thresholding sering dimanfaatkan untuk melakukan segmentasi area tumor [7], sementara teknik peningkatan kontras seperti embossed mampu memperjelas detail lesi struktural pada gambar MRI [1]. Selain itu, metode klasifikasi berbasis machine learning klasik seperti Naïve Bayes yang dikombinasikan dengan ekstraksi fitur Gray Level Co-occurrence Matrix (GLCM) [2] dan Support Vector Machine (SVM) [3] juga telah diterapkan untuk membedakan antara citra otak normal dan yang memiliki tumor. Meskipun metode-metode ini memberikan kontribusi awal, mereka sering kali bergantung pada ekstraksi fitur manual.

Dalam dekade terakhir, metode deep learning, khususnya Convolutional Neural Network (CNN), telah merevolusi bidang analisis citra medis dan menunjukkan keunggulan signifikan dibandingkan metode tradisional. Arsitektur CNN mampu mempelajari fitur-fitur relevan secara otomatis langsung dari data citra, sehingga menghasilkan performa yang lebih unggul dalam tugas klasifikasi dan deteksi. Berbagai penelitian telah berhasil mengimplementasikan arsitektur CNN, baik yang dirancang khusus [5], [6] maupun yang menggunakan model pra-terlatih seperti VGG-16 [4] dan MobileNetV2 [8], untuk mengklasifikasikan berbagai jenis tumor otak seperti Glioma, Meningioma, dan Pituitary dengan tingkat akurasi yang sangat tinggi, bahkan mencapai 95% hingga 99% [4], [5]. Model deep learning seperti YOLOv7 telah diaplikasikan tidak hanya untuk klasifikasi tetapi juga dalam mendeteksi letak tumor secara presisi [9], membuktikan bahwa pendekatan ini sangat adaptif dan kuat dalam konteks diagnosis tumor otak.

Walaupun CNN masih dianggap sebagai standar utama, para peneliti terus mengeksplorasi arsitektur yang lebih inovatif guna meningkatkan performa. Salah satu model terbaru yang menjanjikan hasil luar biasa adalah Vision Transformer (ViT). Berbeda dengan CNN yang berfokus pada fitur lokal, ViT mengadopsi mekanisme self-attention dari model Transformer yang mampu menangkap hubungan kontekstual global dalam sebuah citra, sebuah pendekatan yang terbukti sangat berhasil dalam pemrosesan bahasa alami. Beberapa penelitian awal menunjukkan bahwa ViT memiliki potensi untuk mengungguli model berbasis CNN dalam berbagai tugas pengenalan gambar, termasuk dalam analisis citra medis [10]. Sebuah studi bahkan telah secara spesifik menerapkan ViT untuk deteksi tumor otak pada citra MRI dan berhasil mencapai akurasi sebesar 88% [10]. Berdasarkan potensi dan keberhasilan awal ini, penelitian ini bertujuan untuk mengidentifikasi tumor otak menggunakan model deep learning berbasis Vision Transformer (ViT), dengan harapan dapat memberikan kontribusi pada pengembangan sistem diagnosis yang lebih akurat dan andal.

1.2 Rumusan Masalah

Berdasarkan uraian latar belakang yang telah dipaparkan sebelumnya, yang menekankan pentingnya deteksi dini tumor otak melalui analisis citra MRI serta potensi pemanfaatan teknologi kecerdasan buatan khususnya model Transformer yang diimplementasikan dalam ekosistem PyTorch maka penelitian ini dirancang untuk menjawab sejumlah pertanyaan utama yang menjadi dasar perumusan masalah. Adapun rumusan masalah yang ingin dijawab melalui penelitian ini mencakup hal-hal sebagai berikut:

1. Bagaimana arsitektur Transformer yang diimplementasikan menggunakan PyTorch dapat mengenali pola abnormal pada citra MRI untuk mengidentifikasi keberadaan tumor otak?
2. Sejauh mana tingkat akurasi dan sensitivitas model Transformer yang diimplementasikan dengan PyTorch dalam membedakan citra otak normal dan yang mengandung tumor?

1.3 Batasan Masalah

Untuk menjaga fokus, kejelasan arah, dan kelayakan pelaksanaan penelitian dalam keterbatasan waktu dan sumber daya yang tersedia, maka ruang lingkup penelitian ditetapkan secara spesifik dan batasan-batasan sebagai berikut:

1. Penelitian ini memanfaatkan dataset citra MRI otak yang dapat diakses secara publik melalui platform Kaggle.
2. Pralaku Data (Preprocessing): Meliputi normalisasi intensitas piksel, augmentasi dasar (rotasi dan flipping), serta pengubahan ukuran (resizing); tidak mencakup segmentasi manual atau penandaan (annotation) khusus.
3. Arsitektur Model: Terfokus pada implementasi standar Vision Transformer (ViT) di PyTorch, tanpa mengeksplorasi varian lain
4. Klasifikasi dilakukan secara biner (sehat vs. tumor), tanpa mengelompokkan tumor berdasarkan jenis jaringan atau tingkat keparahan.

5. Lingkup Evaluasi: Kinerja model dievaluasi menggunakan metrik akurasi dan AUC-ROC, tanpa melakukan validasi silang klinis atau uji coba lapangan di rumah sakit.

1.4 Tujuan Penelitian

Tujuan utama dari penelitian ini adalah untuk mengembangkan sebuah model klasifikasi berbasis arsitektur Vision Transformer (ViT) yang diimplementasikan menggunakan framework PyTorch, dengan fokus pada kemampuan mendeteksi keberadaan tumor otak melalui analisis citra MRI. Penelitian ini juga bertujuan untuk membangun kerangka kerja end-to-end yang mencakup seluruh tahapan penting, mulai dari preprocessing data (seperti normalisasi, augmentasi dasar, dan resizing), pelatihan model, hingga evaluasi performa menggunakan metrik akurasi dan AUC-ROC. Kerangka kerja ini diharapkan dapat menjadi dasar atau acuan awal dalam pengembangan sistem berbasis kecerdasan buatan untuk mendukung deteksi dini dan pengambilan keputusan di bidang radiologi, meskipun dalam lingkup terbatas.

1.5 Manfaat Penelitian

Penelitian ini diharapkan memberikan manfaat sebagai berikut:

1. Manfaat Teoritis:

Hasil penelitian ini diharapkan memperkaya pemahaman mengenai pemanfaatan Transformer dalam analisis citra medis, terutama untuk deteksi tumor otak, dan menjadi dasar bagi studi selanjutnya yang berfokus pada penyempurnaan arsitektur atau integrasi data multimodal.

2. Manfaat Praktis:

Penelitian ini juga diharapkan dapat meningkatkan efisiensi tenaga medis dengan menyediakan deteksi otomatis pola abnormal pada citra MRI sehingga waktu interpretasi dapat dipercepat, serta mendukung pengembangan aplikasi klinis di rumah sakit atau pusat riset yang memanfaatkan PyTorch sebagai platform.

1.6 Sistematika Penulisan

Berikut uraian singkat isi setiap bab dalam skripsi ini:

BAB I PENDAHULUAN

Berisi Latar Belakang Masalah, Rumusan Masalah, Batasan Masalah, Tujuan Penelitian, Manfaat Penelitian, dan Sistematika Penulisan.

BAB II TINJAUAN PUSTAKA

Menguraikan kajian literatur terkait tumor otak dan diagnosis citra MRI, dasar-dasar teori Transformer dan Vision Transformer, tinjauan implementasi PyTorch untuk deep learning medis, serta penelitian terdahulu (state of the art) di bidang klasifikasi citra tumor otak.

BAB III METODE PENELITIAN

Menjelaskan metodologi penelitian meliputi rancangan sistem, deskripsi dataset, langkah-langkah preprocessing dan augmentasi data, arsitektur model Vision Transformer, detail implementasi di PyTorch, konfigurasi pelatihan (optimizer, learning rate, batch size), serta prosedur evaluasi performa model.

BAB IV HASIL DAN PEMBAHASAN

Menyajikan hasil eksperimen model Vision Transformer: grafik akurasi dan loss selama pelatihan, matriks kebingungan, nilai metrik (akurasi, sensitivitas, spesifisitas, AUC-ROC), analisis visualisasi attention map, serta perbandingan kinerja dengan model CNN konvensional. Disertai diskusi mendalam mengenai kelebihan, kelemahan, dan potensi peningkatan.

BAB V PENUTUP

Berisi kesimpulan penelitian yang merangkum capaian tujuan, temuan utama dalam identifikasi tumor otak menggunakan Transformer dan PyTorch, serta saran untuk penelitian selanjutnya, seperti pengembangan model multimodal

BAB II

TINJAUAN PUSTAKA

2.1 Studi Literatur

Penelitian terkait deteksi tumor otak dengan metode berbasis citra MRI telah berkembang pesat dalam lima tahun terakhir. Pada level yang paling umum, beberapa studi menyoroti peran peningkatan kualitas citra dan metode segmentasi klasik sebelum klasifikasi. Irmanti et al. menguji berbagai teknik peningkatan citra (embossing, thresholding, negation) untuk mendeteksi area tuberkulum pada MRI, dan menemukan embossing memberikan nilai SSIM tertinggi (0,9345) yang stabil untuk preprocessing citra [1].

Selanjutnya, penelitian-penelitian awal menerapkan metode machine learning tradisional setelah ekstraksi fitur. Laksono et al. memanfaatkan GLCM untuk ekstraksi tekstur dan Naïve Bayes sebagai classifier, dengan akurasi 80% serta precision–recall rata-rata 85%, namun masih terbatas oleh fitur statistik manual [2]. Sinulingga et al. menggunakan metode Support Vector Machine (SVM) untuk klasifikasi jenis tumor glioma, dan mencapai akurasi 91%, menandakan efektivitas SVM namun masih bergantung pada kualitas fitur hand-crafted [3].

Beranjak ke deep learning klasik, Aulia & Alamsyah menerapkan fine-tuning VGG-16 dan mencapai akurasi 95,63%, meski membutuhkan proses tuning yang ekstensif dan sulit diotomasi [4]. Bernadetta & Moses menggunakan CNN 14-layer dan meraih akurasi 98,20% pada epoch ke-100, menunjukkan performa tinggi tetapi memerlukan dataset besar dan jaringan dalam [5]. Azhar et al. membandingkan tiga arsitektur CNN dan menemukan “Model B” unggul dengan akurasi, precision, recall, dan F1-score sekitar 98,86%, namun eksperimen arsitektur tetap memakan waktu [6]. Prayogi et al. mengombinasikan watershed dan thresholding sebelum CNN untuk segmentasi, dengan akurasi 88% dan precision 92%, menandakan metode hybrid yang efektif namun masih rule-based [7].

Penelitian ringan pada arsitektur efisien juga dilakukan: Nafisa et al. mengimplementasikan MobileNetV2 dengan transfer learning pada dataset kecil, mencapai akurasi testing 78,33% dan validasi 83%, tetapi performa menurun pada data tidak seimbang [8]. Kemudian, arsitektur deteksi objek real-time dieksplorasi oleh Passa et al. menggunakan YOLOv7, dimana mAP50 tercatat 93,2% dan F1-score 90,8%, meski model ini menitikberatkan pada bounding-box dan kurang sensitif pada pola mikrotumor [9].

Akhir-akhir ini, studi memanfaatkan transformer untuk menangkap konteks global dalam citra. Akbar et al. menerapkan Vision Transformer (ViT) dengan TensorFlow/Keras dan mencapai akurasi hingga 97,92% pada dataset besar, namun implementasinya belum dioptimalkan di ekosistem PyTorch serta belum difokuskan pada integrasi klinis [10].

Berdasarkan tinjauan di atas, penelitian ini yang berjudul (“Mendeteksi Pola Abnormal: Pemanfaatan Transformer dan PyTorch untuk Identifikasi Tumor Otak”) mengambil peluang untuk:

1. Menggantikan pipeline preprocessing intensif dengan self-attention yang mampu menangkap fitur spasial dan tekstur secara langsung
2. Mengintegrasikan transformer dalam framework PyTorch demi kemudahan deployment klinis
3. Menyederhanakan tuning arsitektur lewat fine-tuning end-to-end

Tabel 2.1 Keaslian Penelitian

No	Judul penelitian	Nama Penulis	Tahun Publikasi	Hasil Penelitian	Perbandingan Penelitian
1	Analisis Komparatif Metode Peningkatan Kualitas Citra Digital untuk Deteksi Area Tubercoluma pada Citra MRI	Kanita Salsabila Dwi Irmanti, Desi Masdin Dama, Taopik Hidayat	2025	Menjelaskan bahwa teknik embossing menghasilkan nilai SSIM tertinggi (0,9345) dan nilai terendah (0,9283), mengindikasikan stabilitas peningkatan kualitas citra	Menjelaskan bahwa dalam penelitian saya, penggunaan arsitektur Transformer memfokuskan langsung pada ekstraksi fitur spasial dan tekstur abnormal tanpa perlu pre-processing intensif seperti embossing, sehingga diharapkan mengefisienkan alur kerja pra-klasifikasi.
2	Deteksi Tumor Otak Melalui Penerapan GLCM dan Naïve Bayes Classification	Puji Laksono, Harliana, Tito Prabowo	2023	Menjelaskan bahwa ekstraksi fitur GLCM dengan klasifikasi Naïve Bayes menghasilkan akurasi 80% serta precision & recall rata-rata 85	Menjelaskan bahwa penelitian saya menggantikan pipeline fitur-statistik dan Naïve Bayes tersebut dengan model Transformer yang belajar langsung representasi fitur tekstur, sehingga diharapkan

					meningkatkan akurasi di atas 85%
3	Klasifikasi Jenis Tumor Otak Berdasarkan Citra Glioma Menggunakan Metode Support Vector Machine	Adam Jordie Sinulingga, Darwis Robinson Manalu, Samuel Manurung	2023	Menjelaskan bahwa penerapan SVM pada citra glioma berhasil mencapai akurasi klasifikasi sebesar 91%, menandakan efektivitas metode dalam membedakan tipe tumor	Menjelaskan bahwa penelitian saya menggantikan tahap ekstraksi fitur manual pada SVM dengan kemampuan self-attention di Transformer, sehingga model dapat belajar pola abnormal langsung dari data gambar tanpa memerlukan fitur hand-crafted.
4	Peningkatan Hiperparameter Framework Deep Learning VGG-16 untuk Pendeteksian Tumor Otak pada MRI	Ahmad Bagas Aditya Ilham Aulia, Alamsyah	2024	Menjelaskan bahwa tuning hiperparameter VGG-16 menghasilkan akurasi 95,63%, precision 95,69%, recall 95,58%, dan F1-score 95,57%	Menjelaskan bahwa penelitian saya memanfaatkan Transformer dengan fine-tuning di PyTorch sebagai alternatif tuning VGG, mengurangi beban tuning hiperparameter manual dan mempercepat waktu pelatihan sambil

					mempertahankan akurasi tinggi.
5	Deteksi Tumor Otak dengan Metode Convolutional Neural Network	Bernadetta Sri Endah Dwi, De Rosal Ignatius Moses Setiadi	2023	Menjelaskan bahwa CNN 14-layer mencapai akurasi 98,20% pada epoch ke-100, menandai performa kuat dalam identifikasi tumor otak	Menjelaskan bahwa penelitian saya memanfaatkan struktur Transformer yang mampu menampung konteks global citra, sehingga diharapkan melampaui kemampuan CNN dalam menangkap pola-pola abnormal yang berskala besar tanpa menambah kedalaman jaringan.
6	Penerapan Algoritma Convolutional Neural Network (CNN) untuk Diagnosa Tumor Otak	Bambang Siswoyo, Azhar dkk.	2024	Menjelaskan bahwa “Model B” dari tiga arsitektur CNN yang diuji memberikan akurasi, precision, recall, dan F1-score sekitar 98,86%, menandakan keseimbangan metrik yang optimal	Menjelaskan bahwa dalam penelitian saya, Transformer diimplementasikan di PyTorch untuk menggantikan seleksi arsitektur CNN, sehingga meminimalkan eksperimen arsitektur berulang dan langsung

					mengoptimalkan self-attention bagi deteksi pola abnormal.
7	Deteksi Tumor Otak Menggunakan Metode Watershed dan Thresholding Pada Citra MRI	Aditya Prayogi, Alda Cendekia Siregar, Rachmat Wahid Saleh Insani	2023	Menjelaskan bahwa kombinasi watershed dan thresholding memberi akurasi 88%, precision 92%, serta recall yang dihitung dari confusion matrix, menunjukkan metode yang sederhana namun efektif	Menjelaskan bahwa penelitian saya mengurangi ketergantungan pada segmentasi berbasis aturan seperti watershed, dengan menggantinya ke dalam framework PyTorch yang langsung mempelajari batas-batas abnormal melalui self-attention, sehingga mempercepat proses deteksi.
8	Implementasi Algoritma CNN Arsitektur MobileNetV2 dalam Klasifikasi Tumor Otak Glioma, Pituitary, Meningioma	Anti Nada Nafisa, Erika Nia Devina Br Purba, Fahri Aulia Alfarisi Harahap, Nurul Adawiyah Putri	2023	Menjelaskan bahwa MobileNetV2 dengan transfer learning mencapai akurasi testing 78,33% dan validasi 83% dalam dataset kecil dan tidak seimbang	Menjelaskan bahwa penelitian saya menggantikan lightweight CNN ini dengan Transformer teroptimasi di PyTorch, sehingga diharapkan meningkatkan

					performa pada dataset kecil berkat kemampuan self-attention mempertahankan informasi penting
9	Deteksi Tumor Otak Pada MRI Menggunakan YOLOv7	Rahma Satila Passa, Siti Nurmaini, Dian Palupi Rini	2023	Menjelaskan bahwa penggunaan YOLOv7 mendapatkan mAP50 93,2%, precision 91,4%, recall 90,4%, dan F1-score 90,8%, serta performa real-time	Menjelaskan bahwa penelitian saya memfokuskan pada klasifikasi pola abnormal dengan Transformer daripada deteksi bounding-box real-time, sehingga model dapat lebih akurat mengidentifikasi area mikrotumor tanpa memerlukan anchor-based detection
10	Deteksi Tumor Otak Melalui Gambar MRI Berdasarkan Vision Transformers dengan Tensorflow dan Keras	Oki Akbar, Ema Utami, Dhani Ariatmanto	2023	Menjelaskan bahwa model Vision Transformer yang dilatih pada dua dataset (253 dan 3.123 citra) berhasil mencapai akurasi	Menjelaskan bahwa penelitian saya memanfaatkan kekuatan Transformer lebih lanjut dengan implementasi di PyTorch, sehingga

				masing-masing 88% dan 97,92%, menunjukkan peningkatan signifikan dalam klasifikasi tumor otak	diharapkan menghasilkan model yang tidak hanya akurat tetapi juga lebih mudah diintegrasikan ke dalam pipeline klinis dibandingkan implementasi berbasis TensorFlow.
--	--	--	--	--	--

2.2 Dasar Teori

2.2.1 Citra Magnetic Resonance Imaging (MRI)


Magnetic Resonance Imaging (MRI) merupakan teknik pencitraan medis non-invasif yang memanfaatkan resonansi nuklir proton pada medan magnet kuat untuk menghasilkan penampang jaringan lunak tubuh, termasuk otak. Proses ini memerlukan perangkat khusus, seperti yang dapat dilihat pada **Gambar 2.1**. Kontras intensitas pada citra MRI dipengaruhi oleh densitas proton dan waktu relaksasi jaringan, perbedaan ini memungkinkan pembedaan struktur anatomi dan patologi seperti tumor.



Gambar 2.1. Mesin MRI

2.2.2 Pengolahan Citra Digital

Pengolahan citra digital melibatkan serangkaian tahapan untuk mempersiapkan dan menganalisis data gambar. Tahapan ini mencakup pra-pemrosesan, seperti reduksi *noise* dan normalisasi intensitas, segmentasi untuk memisahkan area objek dari latar belakang, serta ekstraksi fitur yang meliputi tekstur, tepi, dan bentuk. Sebagai contoh, proses pra-pemrosesan pada citra digital MRI dapat dilihat pada **Gambar 2.2**.



Gambar 2.2. Contoh Pra-pemrosesan Citra Digital MRI

2.2.3 Deep Learning untuk Klasifikasi Citra

Deep learning end-to-end, khususnya Convolutional Neural Network (CNN), telah terbukti unggul dalam ekstraksi fitur otomatis dari citra medis. Lapisan konvolusi belajar kernel yang merespon pola lokal (tepi, tekstur), sedangkan pooling mereduksi dimensi spasial. Meski akurasi tinggi dicapai (~98 % pada CNN 14-layer), model CNN tradisional kurang efektif menangkap konteks global dan memerlukan eksperimen arsitektur intensif.

2.2.4 Arsitektur Transformer dan Self-Attention

Transformer pertama kali diperkenalkan oleh Vaswani et al. sebagai sebuah arsitektur yang mengandalkan mekanisme self-attention, dengan tujuan mengatasi keterbatasan model berbasis urutan seperti RNN dan LSTM, yang memiliki ketergantungan terhadap pemrosesan sekuensial. Arsitektur Transformer terdiri dari beberapa komponen utama, yaitu:

1. Self-Attention

Mekanisme yang memungkinkan model untuk memperhitungkan hubungan antar elemen dalam satu urutan secara langsung, tanpa perlu memproses data secara berurutan.

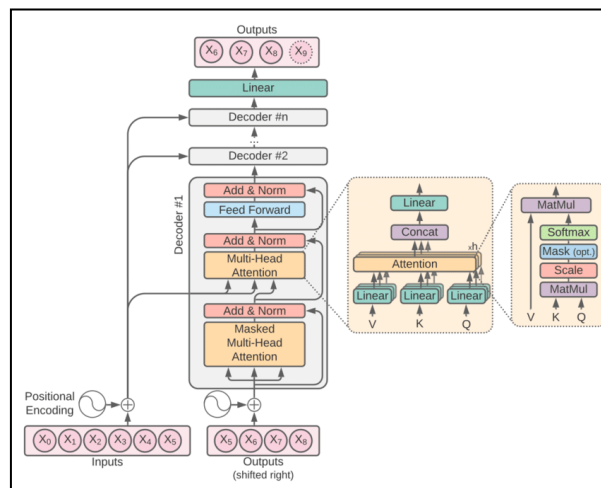
2. Multi-Head Attention

Strategi untuk menjalankan beberapa operasi self-attention secara paralel, sehingga model dapat menangkap

informasi dari berbagai representasi subruang secara bersamaan.

3. Positional Encoding

Teknik yang digunakan untuk menyisipkan informasi urutan posisi ke dalam input, karena tidak adanya mekanisme sekuensial seperti pada *Recurrent Neural Network* (RNN), adalah *positional encoding*. Konsep ini merupakan bagian integral dari arsitektur Transformer dan mekanisme *self-attention* yang dijelaskan pada **Gambar 2.3**.



Gambar 2.3. Arsitektur Transformer dan Self-Attention

2.2.5 Framework PyTorch

PyTorch merupakan sebuah library deep learning berbasis paradigma imperatif yang mendukung komputasi dinamis (define-by-run), sehingga memungkinkan fleksibilitas tinggi dalam proses pengembangan dan eksperimen model. Beberapa fitur kunci yang menjadi keunggulan PyTorch antara lain:

1. Autograd:

Menyediakan mekanisme otomatis untuk melakukan diferensiasi balik (backpropagation), sehingga mempermudah proses optimisasi model secara efisien.

2. Modularitas:

Memungkinkan pengguna untuk dengan mudah mendefinisikan berbagai komponen model, seperti layer, loss function, dan optimizer, dalam struktur yang terorganisir dan dapat disesuaikan.

3. TorchScript:

Menyediakan fasilitas untuk mengubah model dinamis menjadi bentuk statik yang dapat digunakan dalam proses deployment, termasuk di lingkungan produksi atau aplikasi klinis.

2.2.6 Metode Evaluasi

Evaluasi kinerja model klasifikasi tumor otak pada citra MRI dilakukan dengan menggunakan sejumlah metrik evaluatif yang umum digunakan dalam bidang pembelajaran mesin dan pengolahan citra medis. Metrik-metrik tersebut mencerminkan sejauh mana model mampu membedakan antara citra otak normal dan citra yang mengindikasikan keberadaan tumor. Adapun metrik yang digunakan dalam penelitian ini meliputi:

2.2.6.1 Akurasi

Akurasi mengukur proporsi total prediksi yang benar (baik positif maupun negatif) terhadap keseluruhan jumlah sampel. Metrik ini memberikan gambaran umum mengenai performa model secara keseluruhan.

2.2.6.2 Presisi (Precision)

Presisi merepresentasikan rasio antara jumlah prediksi positif yang benar terhadap seluruh prediksi positif yang dihasilkan model. Nilai presisi yang tinggi menunjukkan bahwa model memiliki tingkat kesalahan positif yang rendah.

2.2.6.3 Recall

Recall atau sensitivitas mengukur kemampuan model dalam mengidentifikasi kasus positif secara benar, yaitu sejauh mana model mampu mendeteksi keberadaan tumor ketika memang ada.

2.2.6.4 F1-Score

F1-score merupakan rata-rata harmonis antara precision dan recall. Metrik ini sangat berguna dalam situasi di mana keseimbangan antara presisi dan sensitivitas menjadi penting, khususnya ketika data tidak seimbang.

2.2.6.5 AUC-ROC

AUC-ROC mengevaluasi kemampuan model dalam membedakan antara kelas positif dan negatif di berbagai ambang keputusan. Nilai AUC yang mendekati 1 menunjukkan bahwa model memiliki kemampuan klasifikasi yang sangat baik, sedangkan nilai mendekati 0,5 menunjukkan bahwa model tidak lebih baik daripada tebakan acak. Metrik ini sangat penting dalam konteks diagnosis medis karena memperhitungkan trade-off antara true positive rate (sensitivitas) dan false positive rate di seluruh ambang batas klasifikasi.

BAB III METODE PENELITIAN

3.1 Objek Penelitian

Objek penelitian dalam penelitian ini adalah citra Magnetic Resonance Imaging (MRI) otak publik yang diperoleh dari situs Kaggle dengan nama “Brain MRI Images for Brain Tumor Detection”. Dataset ini terdiri dari dua kelas utama citra otak normal (no tumor) dan citra otak bermasalah (tumor) dengan total sekitar 4.600 citra beresolusi bervariasi. Setiap citra telah di-label secara biner sesuai keberadaan tumor, tanpa informasi lebih lanjut mengenai tipe histologi. Penelitian ini bertujuan membangun model klasifikasi biner untuk mendeteksi keberadaan tumor otak pada citra MRI dengan memanfaatkan arsitektur Vision Transformer (ViT) yang diimplementasikan menggunakan framework PyTorch.

3.2 Alur Penelitian

Tahap alur penelitian ini menjelaskan secara rinci prosedur dan urutan langkah-langkah yang dilakukan dalam penelitian. Proses ini divisualisasikan dalam bentuk bagan alur (*flowchart*), seperti yang ditunjukkan pada **Gambar 3.1**. Setiap tahapan dalam bagan tersebut akan diuraikan lebih lanjut.



Gambar 3.1 Alur Penelitian

Berikut adalah uraian penjelasan dari masing-masing tahapan alur penelitian :

3.2.1 Identifikasi Masalah

Menentukan gap penelitian terkait deteksi dini tumor otak melalui analisis citra MRI, serta potensi penerapan arsitektur Transformer untuk memperbaiki akurasi dan efisiensi dibandingkan metode konvolusional.

3.2.2 Studi Literatur

Melakukan telaah pustaka mendalam pada penelitian-penelitian terdahulu mengenai klasifikasi citra tumor otak, pemanfaatan CNN dan Transformer atau model lainnya, serta implementasi di ekosistem PyTorch.

3.2.3 Pengumpulan Data

Mengunduh dan menyiapkan dataset “Brain MRI Images for Brain Tumor Detection” yang berisi citra-citra MRI otak normal dan tumor dari Kaggle. Memastikan integritas data dan kelengkapan label.

3.2.4 Data Preprocessing

Melakukan pra-pemrosesan meliputi:

- a) Normalisasi Intensity: Menskalakan pixel values ke rentang [0, 1].
- b) Resizing: Mengubah dimensi citra menjadi 224×224 piksel sesuai kebutuhan ViT.
- c) Augmentasi Dasar: Rotasi ($\pm 15^\circ$), flipping horizontal, dan zoom ringan untuk memperkaya variasi data.
- d) Quality Check: Menghapus citra buram atau artefak berat.

3.2.5 Pemisahan Data (Training dan Testing)

Membagi data yang telah diproses menjadi set pelatihan (training) dan pengujian (testing) dengan rasio 80 : 20. Pengacakan (shuffle) dilakukan sebelum pembagian untuk memastikan distribusi label seimbang.

3.2.6 Modeling

Model yang digunakan adalah arsitektur Vision Transformer varian ViT-Base/16, diimplementasikan sepenuhnya dalam framework PyTorch. Setiap citra MRI dibagi menjadi patch-patch berukuran 16×16 piksel, kemudian setiap patch diubah menjadi vektor embedding berdimensi 768. Vektor-vektor embedding ini diproses melalui 12 head pada lapisan multi-head self-attention, sehingga model mampu menangkap hubungan spasial global antar-patch pada citra.

Seluruh jaringan ViT difine-tune secara end-to-end menggunakan dataset MRI yang telah melalui tahap pra-pemrosesan. Penyesuaian hyperparameter termasuk optimizer AdamW, learning rate, batch size, dan jumlah epoch dilakukan melalui validasi silang pada data training untuk memperoleh konfigurasi terbaik. Setelah pelatihan selesai, bobot model ViT disimpan untuk kemudian dievaluasi pada data testing.

3.2.7 Perbandingan Evaluasi Model

Kinerja Vision Transformer (ViT) dievaluasi secara komprehensif dengan metrik-metrik utama: akurasi, yang mengukur proporsi total prediksi benar baik positif maupun negatif; precision, yaitu rasio antara prediksi positif yang benar dengan seluruh prediksi positif; recall (sensitivitas), menggambarkan kemampuan model dalam mendeteksi citra yang benar-benar mengandung tumor; F1-score, rata-rata harmonis antara precision dan recall untuk menilai keseimbangan keduanya; dan AUC-ROC, area di bawah kurva Receiver Operating Characteristic yang mencerminkan kemampuan model membedakan kelas positif dan negatif pada berbagai ambang keputusan. Selain nilai-nilai kuantitatif ini, disajikan pula confusion matrix untuk memvisualisasikan distribusi prediksi benar dan salah, serta plot ROC untuk menilai trade-off antara true positive rate dan false positive rate pada setiap threshold.

3.2.8 Deployment dan Analisis Performa Model

Tahap ini merupakan langkah akhir dari alur penelitian, yaitu menguji model yang telah dibangun menggunakan data uji untuk mengevaluasi kemampuan sistem dalam melakukan klasifikasi citra MRI otak. Model yang digunakan adalah Vision Transformer (ViT), yang telah dilatih pada data latih citra MRI. Proses uji coba dilakukan dengan memasukkan citra MRI ke dalam sistem melalui antarmuka pengguna (user interface) yang telah dirancang. Setelah gambar dimasukkan, sistem akan memproses citra menggunakan model ViT, lalu memberikan hasil prediksi berupa label dan nilai akurasi.

3.2.9 Analisa Hasil

Hasil evaluasi model ViT kemudian dianalisis secara menyeluruh untuk menarik kesimpulan yang tepat. Perbandingan dilakukan berdasarkan metrik performa pada data testing termasuk akurasi, precision, recall, F1-score, dan AUC-ROC. Analisis mempertimbangkan efektivitas model dalam mendeteksi keberadaan tumor, efisiensi komputasi dan waktu inferensi, serta kemampuan generalisasi terhadap citra MRI yang belum pernah dilihat sebelumnya. Dari tinjauan kuantitatif dan kualitatif ini, direkomendasikan kondisi dan konfigurasi ViT yang paling optimal untuk sistem deteksi dini tumor otak, sekaligus mengidentifikasi area perbaikan untuk penelitian lanjutan.

3.3 Alat dan Bahan

Berikut alat dan bahan yang diperlukan dalam penelitian ini:

- 1) **Data Penelitian**, Dataset citra MRI otak publik “Brain MRI Images for Brain Tumor Detection” yang diunduh dari Kaggle, berisi dua kelas (normal vs. tumor) dengan total sekitar 3.000-4.000 gambar berlabel biner.

2) Alat/Instrumen, Peneliti menggunakan Google Colab dan bahasa pemrograman Python dengan library PyTorch (serta timm, torchvision), scikit-learn, dan matplotlib untuk seluruh proses penelitian, mulai dari pra-pemrosesan data, pelatihan model.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Pengumpulan Data

Dalam penelitian ini peneliti menggunakan gambar Magnetic Resonance Imaging (MRI) otak yang diperoleh dari situs Kaggle untuk mendeteksi keberadaan tumor. Jumlah gambar yang digunakan sebanyak 4.600 yang tertera di **Tabel 4.1**, dengan setengahnya menunjukkan kondisi otak sehat dan setengahnya lagi menunjukkan adanya tumor. Setiap gambar diubah ukurannya agar lebih seragam dan dilakukan beberapa teknik sederhana seperti memutar atau membalik gambar, sehingga jumlah data menjadi lebih banyak dan model dapat belajar lebih baik.

Proses pembelajaran mesin dilakukan dengan memanfaatkan layanan komputasi awan (cloud) yang dilengkapi dengan kartu grafis (GPU) agar pelatihan model berjalan lebih cepat. Hasil pengujian kemudian dihitung untuk mengetahui seberapa sering model tersebut benar dalam memprediksi kondisi otak.

Tabel 4.1 Komposisi Dataset

Kelas Dataset	Jumlah Citra
Indikasi Tumor Otak (Tumor)	2.513
Otak Sehat (Sehat)	2.087
Total	4.600

4.2 Data Preprocessing

Pada tahap ini, data preprocessing dilakukan untuk mempersiapkan citra otak (brain tumor) agar siap digunakan dalam proses pelatihan dan validasi model Vision Transformer (ViT). Proses ini mencakup beberapa langkah utama: mounting Google Drive, pembacaan metadata, pembagian data (split), definisi augmentasi dan normalisasi, pembuatan dataset, serta visualisasi eksplorasi data.

4.2.1 Definisi Transformasi dan Augmentasi

Transformasi pada data citra bertujuan meningkatkan **keragaman (robustness) model** terhadap variasi citra nyata. Seperti yang tertera pada **Tabel 4.2** di bawah, terdapat dua kelompok utama transformasi

Tabel 4.2 Transformasi dan Augmentasi yang dilakukan

Transformasi	Kategori	Deskripsi	Parameter Utama
Resize	Preprocessing	Mengubah ukuran citra menjadi seragam	output size: (224, 224)
RandomHorizontalFlip	Augmentasi	Membalik citra secara horizontal secara acak	p=0.5 (50 % dari sampel)
RandomVerticalFlip	Augmentasi	Membalik citra secara vertikal secara acak	p=0.5
RandomRotation	Augmentasi	Memutar citra secara acak dalam rentang sudut tertentu	$\pm 30^\circ$
RandomResizedCrop	Augmentasi	Memotong area acak dari citra lalu di-resize kembali	size=224, scale=(0.8, 1.0)
ColorJitter	Augmentasi	Mengubah kecerahan (brightness) citra secara acak	brightness=0.3
ToTensor	Preprocessing	Mengonversi PIL Image / NumPy array ke tensor PyTorch dengan rentang [0,1]	-
Normalize	Preprocessing	Menormalisasi tiap channel RGB sesuai mean/std ImageNet	mean=[0.485,0.456,0.406],std=[0.229,0.224,0.225]
RandomResized	Preprocessing	(Hanya resize dan crop ulang—digunakan di validasi jika ada)	size=224, scale=(0.8, 1.0)

4.3 Pembagian Data (Train–Validation Split)

Pembagian data penelitian ke dalam set data latih (80%) dan set data validasi (20%) dilakukan untuk menjamin keandalan serta generalisasi model. Proses ini, yang dapat dilihat lebih rinci pada **Tabel 4.3**, diimplementasikan dengan memanfaatkan paket split-folders.

Tabel 4.3 Pembagian Data

Split	Fungsi	Seed	Proporsi	Folder Output
Train	splitfolders.ratio(...)	20	80 %	brain_split/train
Validasi	splitfolders.ratio(...)	20	20 %	brain_split/val

4.4 Modeling

Pelatihan model dilakukan dengan pengaturan sebagai berikut, seperti yang tertera pada **Tabel 4.4**

Tabel 4.4 Pengaturan Pelatihan

Parameter	Nilai	Keterangan
Epochs	60	Jumlah iterasi penuh melalui seluruh dataset pada fase training
Batch Size	32	Jumlah sampel yang diproses sekaligus sebelum melakukan update bobot
Learning Rate	1×10^{-4}	Laju pembelajaran awal untuk optimizer AdamW
Optimizer	AdamW	Optimizer Adam dengan weight decay untuk mengurangi overfitting
Weight Decay	0.01	Koefisien regularisasi L2 untuk penalti bobot besar
Scheduler	ReduceLROnPlateau	Menurunkan learning rate jika val_loss tidak membaik setelah 3 epoch berturut-turut
Data Split	80 % train / 20 % val	Pembagian data untuk training dan validasi
Sample per Kelas	{Brain Tumor, Healthy}	Jumlah gambar tiap kelas dicatat

Input Size	224 × 224	Ukuran citra input setelah transformasi resize
Patch Size (ViT)	16	Ukuran patch persegi (16×16) yang dipecah oleh Vision Transformer
Embedding Dim	768	Dimensi vektor embedding tiap patch
Num. Heads	8	Jumlah attention head di setiap layer Transformer
Depth (layers)	12	Jumlah lapisan encoder Transformer
MLP Dim	3072	Ukuran hidden layer pada MLP di dalam tiap block Transformer

Pada tahap pelatihan, peneliti menjalankan proses belajar model Vision Transformer selama 60 siklus penuh menggunakan kelompok data berukuran 32 gambar sekaligus. Untuk membantu model belajar secara efisien sekaligus mencegah kelebihan kecocokan pada data (overfitting), digunakan algoritma AdamW sebuah metode penyesuaian bobot yang dibekali aturan tambahan untuk menjaga bobot agar tidak membesar tak terkendali. Kecepatan belajar awalnya diatur cukup rendah, lalu secara otomatis diperlambat bila ukuran kesalahan pada data uji (val_loss) tidak menurun setelah tiga putaran berturut-turut, agar model tidak berhenti belajar di level yang kurang optimal. Gambar yang digunakan kemudian dibagi 80 % untuk melatih model, dan 20 % sisanya dipakai untuk mengecek sejauh mana kemampuan generalisasi model sebelum digunakan. Kita pastikan tiap kelas (Tumor dan Sehat) memiliki jumlah contoh yang seimbang agar pengukuran performa menjadi adil.

Setiap gambar diubah ukurannya menjadi 224×224 piksel, kemudian dipotong-potong menjadi kotak-kotak kecil ukuran 16×16 piksel. Dari setiap kotak ini, model membangun representasi angka (embedding) berdimensi 768. Selanjutnya diproses melalui 12 lapis pengolah transformer, di mana di setiap lapis terdapat delapan mata atensi yang saling bekerja sama untuk memahami hubungan antar-potongan gambar. Pada akhirnya, setiap lapis juga memiliki jaringan kecil (MLP) berukuran 3072 unit untuk menyaring dan memperkuat informasi penting sebelum melangkah ke lapis berikutnya. Dengan cara ini, model

belajar mengerti pola-pola halus pada citra MRI otak dan membedakan antara kondisi sehat dan tumor.

4.4.1 Lingkungan Eksperimen

Komponen-komponen yang membentuk lingkungan eksperimen selama penelitian model dapat dirinci pada **Tabel 4.5**, yaitu:

Tabel 4.5 Lingkungan Eksperimen

Komponen	Spesifikasi / Versi	Keterangan
Runtime	Google Colab (GPU: Tesla T4)	Menggunakan GPU cloud gratis untuk mempercepat training model
RAM	≤ 25 GB	Kapasitas memori Colab Free untuk memuat data dan model
OS	Linux (container Colab)	Sistem operasi berbasis Linux di lingkungan notebook Colab
Python	3.8.x	Versi Python bawaan Google Colab, kompatibel dengan PyTorch dan library terkait
PyTorch	$\geq 1.12.0$	Framework utama untuk definisi model dan training loop
torchvision	$\geq 0.13.0$	Utilities untuk dataset dan transformasi citra
timm	$\geq 0.6.12$	Library untuk memuat model ViT pretrained
torch-summary	$\geq 1.4.5$	Menampilkan ringkasan arsitektur model sebelum training
scikit-learn	≥ 1.0	Menghitung metrik evaluasi (confusion matrix, classification report, ROC AUC)
matplotlib	≥ 3.4	Visualisasi loss, confusion matrix, histogram, dan ROC curve
seaborn	≥ 0.11	Mempercantik tampilan heatmap pada confusion matrix
OpenCV	≥ 4.5	Membaca citra grayscale dan menghitung distribusi pixel
split-folders	≥ 0.4	Memisahkan dataset menjadi train/val secara otomatis

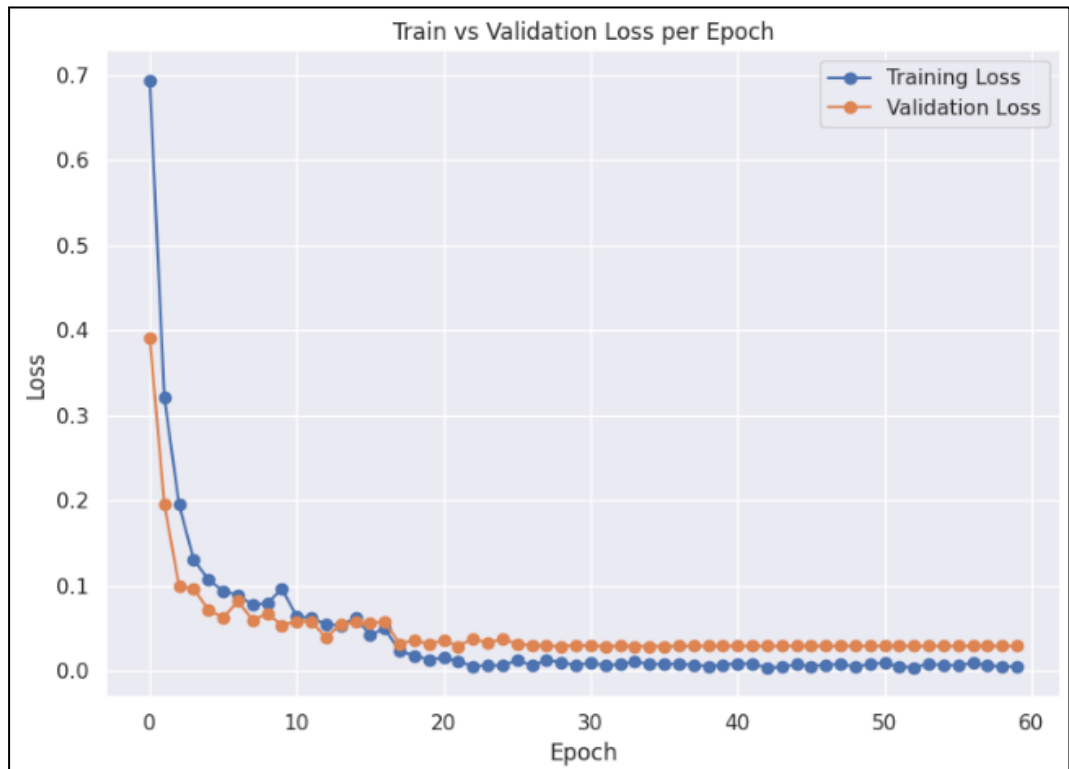
Peneliti menggunakan Google Colab sebuah ruang kerja online gratis yang sudah dilengkapi GPU Tesla T4 dan memori (RAM) hingga sekitar 25 GB. Di dalamnya, seluruh proses berjalan di atas sistem operasi Linux tanpa repot instalasi manual, peneliti menggunakan bahasa pemrograman Python versi 3.8 . Di inti pelatihan, kita mengandalkan PyTorch sebagai kerangka kerja utama. Bayangkan PyTorch seperti kerangka mobil yang kokoh, sementara paket tambahan seperti torchvision memudahkan kita memuat dan memodifikasi gambar, timm menyediakan model ViT yang sudah dilatih sebelumnya, dan torch-summary memberi ringkasan detail struktur model sebelum dipakai. Semua itu membuat kita bisa membangun dan menyesuaikan model deteksi tumor otak dengan lebih cepat dan mudah.

Setelah model berjalan, kita perlu menilai seberapa baik ia bekerja. Untuk itulah scikit-learn hadir menghitung metrik-metrik penting seperti akurasi dan ROC AUC, lalu matplotlib dan seaborn menyajikan grafik serta peta warna untuk memvisualisasikan hasilnya. Sementara itu, OpenCV membantu membaca dan mengolah gambar misalnya mengubah ke skala abu-abu dan split-folders otomatis memisahkan data menjadi folder latih dan uji sesuai yang kita inginkan. Dengan komposisi alat ini, seluruh rangkaian pelatihan dan evaluasi model bisa dilakukan dalam satu kesatuan yang praktis di Google Colab.

4.5 Perbandingan Evaluasi Model

Pada tahap ini disajikan gambaran perubahan nilai loss dan akurasi selama proses pelatihan model. Kurva pelatihan (training) dan validasi (validation) akan memperlihatkan seberapa cepat model belajar dari data, serta sejauh mana model mampu menggeneralisasi pada data yang belum pernah dilihat sebelumnya. Dengan mengamati kedua kurva ini, kita dapat menilai kestabilan pelatihan, mendeteksi potensi overfitting, dan menentukan titik konvergensi pelatihan.

4.5.1 Grafik Loss vs Epoch




Gambar 4.1 Visualisasi Train Vs Validation Loss Per Epoch

Analisis terhadap kurva *loss* vs. *epoch* yang disajikan pada **Gambar 4.1** menunjukkan bahwa nilai *loss* pada data pelatihan dan validasi merefleksikan tingkat kesalahan model di setiap iterasi pelatihan. Pada *epoch* awal, kedua kurva menunjukkan penurunan yang sangat signifikan, mengindikasikan efisiensi model dalam menangkap pola fundamental pada citra MRI dan mengurangi kesalahan prediksi secara drastis. Selanjutnya, laju penurunan *loss* melambat, menandakan fase penyempurnaan progresif terhadap pengetahuan yang telah diakuisisi.

Menjelang *epoch* pertengahan hingga akhir, observasi menunjukkan konvergensi kedua kurva *loss* yang cenderung paralel dan mendekati nilai asimtotik minimal, yang mengindikasikan tercapainya titik optimal dalam perbaikan kesalahan. Perbedaan yang minimal antara *loss* pelatihan dan *loss* validasi menegaskan kemampuan generalisasi model yang kuat, menandakan bahwa model tidak hanya mampu mengingat data

latih, tetapi juga efektif dalam membuat prediksi akurat pada data baru. Secara keseluruhan, pola ini menggambarkan proses pelatihan yang stabil dan optimal, dari pembelajaran cepat di awal hingga pencapaian kinerja yang konsisten.

4.5.2 Confusion Matrix



Gambar 4.2 Confusion Matrix

Dari **Gambar 4.2**, dapat diamati bahwa confusion matrix ini menyajikan gambaran komprehensif evaluasi model klasifikasi terhadap citra MRI otak pada data uji. Matriks tersebut merangkum secara kuantitatif prediksi yang akurat dan tidak akurat oleh model untuk masing-masing kelas target.

Detail hasilnya sebagai berikut:

- **True Positive (TP):** 500 citra yang benar-benar *Brain Tumor* dan diprediksi sebagai *Brain Tumor*.
- **True Negative (TN):** 417 citra yang benar-benar *Healthy* dan diprediksi sebagai *Healthy*.
- **False Positive (FP):** 1 citra *Healthy* yang keliru diprediksi sebagai *Brain Tumor*.
- **False Negative (FN):** 3 citra *Brain Tumor* yang keliru diprediksi sebagai *Healthy*.

Visualisasi confusion matrix menggunakan gradasi warna biru, di mana warna yang lebih gelap menunjukkan jumlah prediksi yang lebih tinggi.

4.5.3 Metrik Kinerja

Classification Report:				
	precision	recall	f1-score	support
Brain Tumor	1.00	0.99	1.00	503
Healthy	0.99	1.00	1.00	418
accuracy			1.00	921
macro avg	1.00	1.00	1.00	921
weighted avg	1.00	1.00	1.00	921

Gambar 4.3 Metrik Kinerja

Metrik kinerja model, sebagaimana disajikan pada **Gambar 4.3**, secara jelas mengindikasikan kualitas yang sangat baik dan menjanjikan. Gambaran ini menunjukkan kapabilitas model yang solid dalam klasifikasi. Rincian lebih lanjut dari metrik tersebut akan dijelaskan di bawah ini:

1. Akurasi

Akurasi model sebesar 1.00, yang menunjukkan bahwa hampir seluruh citra pada data uji berhasil diklasifikasikan dengan benar.

2. Presisi

- *Brain Tumor*: 1.00
- *Healthy*: 0.99

Presisi mengukur seberapa banyak prediksi positif yang benar-benar positif.

3. Recall (Sensitivitas)

- *Brain Tumor*: 0.99
- *Healthy*: 1.00

Recall mengukur kemampuan model mendeteksi seluruh data positif secara benar.

4. Spesifisitas

- True Negative (TN) = 417
- False Positive (FP) = 1

Spesifisitas mengukur kemampuan model dalam mengidentifikasi citra yang benar-benar negatif secara benar.


5. F1-Score

- *Brain Tumor*: 1.00
- *Healthy*: 1.00

F1-Score adalah rata-rata harmonis presisi dan recall, mencerminkan keseimbangan antara kedua metrik tersebut.

4.5.4 Receiver Operating Characteristic (ROC) Curve

ROC (Receiver Operating Characteristic) Curve adalah grafik yang memetakan kinerja model klasifikasi pada berbagai ambang (threshold) keputusan dengan membandingkan True Positive Rate (TPR) terhadap False Positive Rate (FPR).



Gambar 4.4 Evaluasi ROC AUC Score

Evaluasi kinerja diskriminasi model ditampilkan melalui kurva ROC pada **Gambar 4.4**. Pada grafik ini, sumbu horizontal mewakili *False Positive Rate* (FPR) proporsi citra sehat yang salah diklasifikasikan sebagai tumor dan sumbu vertikal merepresentasikan *True Positive Rate* (TPR) atau sensitivitas proporsi citra tumor yang berhasil dideteksi. Garis diagonal putus-putus menggambarkan performa klasifikasi acak; semakin jauh kurva ROC (biru) bergeser ke arah pojok kiri atas dari diagonal, semakin superior kemampuan diskriminasi model.

Kurva yang disajikan menunjukkan pola menempel pada sumbu vertikal dan kemudian melandai mendekati sumbu horizontal. Karakteristik ini mengindikasikan *False Positive Rate* yang sangat minimal, dengan *True Positive Rate* yang mendekati nilai 1 pada sebagian besar rentang *threshold*. Konfirmasi terhadap kinerja superior ini diperkuat

oleh nilai *Area Under the Curve* (AUC) sebesar 0,9994. Angka ini secara spesifik berarti model memiliki probabilitas 99,94% untuk secara akurat membedakan antara sampel tumor dan sampel sehat dalam pasangan kasus acak.

4.5.5 Hasil Evaluasi

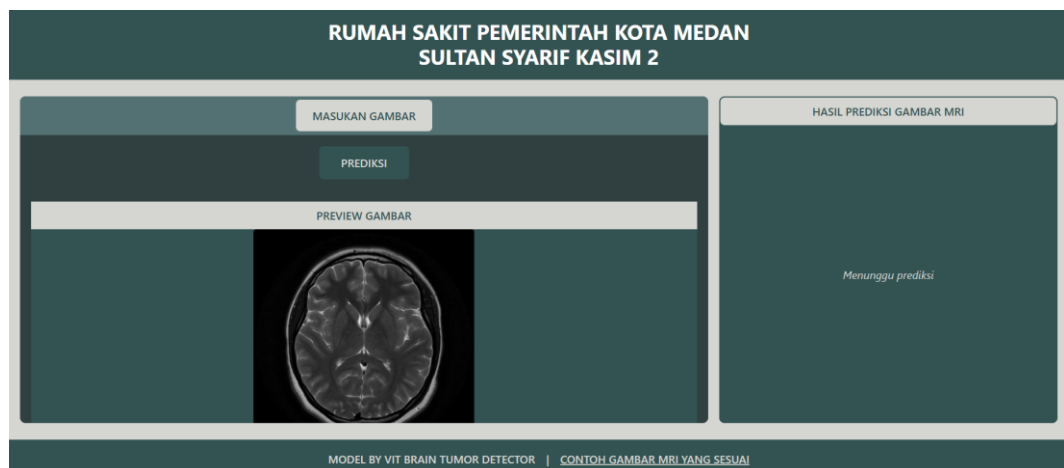
Evaluasi yang telah dilakukan mengungkapkan kualitas model yang luar biasa dan validitas yang tinggi. Data menunjukkan bahwa model tidak hanya memenuhi, tetapi bahkan melampaui ekspektasi dalam mengolah dan menghasilkan keluaran yang akurat. Ini adalah bukti keberhasilan metodologi yang diterapkan.

4.6 Deployment dan Analisis Performa Model



Gambar 4.5 Tampilan Awal

Pada **Gambar 4.5** di perlihatkan tampilan awal dari model yang sudah di buat, model dibuat dengan sederhana dan mudah digunakan



Gambar 4.6 Tampilan Preview Gambar

Selanjutnya pada **Gambar 4.6** di lakukan penginputan gambar Citra MRI dan a kan di perlihatkan gambarnya di bagian Preview Gambar user mengetahui bahwa gambar yang dimasukan memang gambar yang sesuai



Gambar 4.7 Tampilan Hasil Prediksi

Untuk memvisualisasikan kapabilitas sistem yang dibangun, **Gambar 4.7 Tampilan Hasil Prediksi** menyajikan antarmuka pengguna saat pengujian. Citra MRI otak diinput ke dalam sistem yang mengimplementasikan model Vision Transformer (ViT) untuk deteksi tumor. Gambar input divisualisasikan pada bagian *Preview Gambar*, dan keluaran prediksi model disajikan pada panel *Hasil Prediksi Gambar MRI*.

4.6.1 Pembahasan

Berdasarkan hasil evaluasi model Vision Transformer (ViT) pada citra MRI otak, model menunjukkan performa sangat baik dengan akurasi hampir sempurna, AUC-ROC mendekati 1, serta nilai precision dan recall yang tinggi untuk kedua kelas (tumor dan sehat). Hasil ini mengindikasikan bahwa penerapan mekanisme self-attention dalam ViT mampu menangkap pola spasial dan tekstur abnormal pada citra MRI dengan sangat efektif. Namun demikian, ada beberapa hal yang perlu dikaji lebih lanjut agar temuan ini dapat dipertanggungjawabkan secara ilmiah dan diadaptasi ke konteks klinis

4.7 Analisis Hasil

1. Performa Hasil

- Model mencapai akurasi 100 % pada data uji, dengan nilai AUC-ROC sebesar 0,9994, yang menunjukkan kemampuan diskriminasi antara citra tumor dan sehat hampir sempurna .
- Nilai precision untuk kelas Brain Tumor sebesar 1,00 dan recall sebesar 0,99, mengindikasikan bahwa hampir seluruh pasien dengan tumor terdeteksi dengan benar, sementara false positive dan false negative sangat minim .

2. Stabilitas Pelatihan

- Grafik loss menunjukkan konvergensi yang cepat dan stabil, dengan gap yang sangat kecil antara loss training dan validation pada akhir epoch, menandakan risiko overfitting yang rendah pada dataset ini .
- Kurva ROC hampir menempel pada sumbu vertikal dan horizontal, memperlihatkan bahwa meskipun threshold berubah-ubah, model tetap mempertahankan true positive rate tinggi dan false positive rate rendah

4.7.1 Interpretasi Kelemahan & Keterbatasan

1. Keterbatasan Dataset

- Dataset hanya mencakup dua kelas (tumor vs. sehat) tanpa membedakan tipe atau tingkat keganasan tumor, sehingga generalisasi model terhadap skenario multi-kelas atau tumor dengan karakteristik berbeda masih belum teruji.
- Jumlah citra (4.600) relatif terbatas dan bersumber dari satu repository publik. Variasi peralatan MRI, protokol pengambilan citra, dan populasi pasien bisa berbeda di dunia nyata.

2. Kurangnya Validasi Klinis

- Model hanya diuji secara retrospective pada data uji internal (split 80 : 20). Belum ada uji coba pada dataset eksternal maupun uji klinis di rumah sakit untuk menilai kinerja pada kondisi operasional sesungguhnya.

3. Keterbatasan Interpretabilitas

- Meskipun ViT dapat menghasilkan attention map, penjelasan keputusan model (why and where) belum divalidasi secara kuantitatif. Radiolog memerlukan interpretasi visual yang jelas untuk kepercayaan klinis.

BAB V PENUTUP

5.1 Kesimpulan

Berdasarkan hasil pengujian dan pembahasan, dapat disimpulkan bahwa model Vision Transformer (ViT) yang dikembangkan telah berhasil melakukan klasifikasi citra MRI otak menjadi dua kategori tumor dan sehat dengan tingkat akurasi yang mendekati sempurna. Nilai AUC-ROC sebesar 0,9994 serta precision dan recall masing-masing mendekati 1 menunjukkan bahwa model ini mampu membedakan citra yang mengandung tumor dari yang normal dengan sangat andal. Proses pelatihan yang cepat mencapai konvergensi dan menunjukkan perbedaan minimal antara loss pada data pelatihan dan validasi menandakan bahwa overfitting dapat terkontrol pada data uji internal. Meskipun demikian, keterbatasan dataset yang relatif kecil dan hanya berasal dari satu sumber publik membatasi generalisasi hasil ini ke kondisi nyata. Selain itu, model belum diuji pada data eksternal maupun dalam ujicoba klinis, dan aspek interpretabilitas keputusan model masih perlu ditingkatkan agar hasil prediksi dapat dipertanggungjawabkan secara visual oleh tenaga medis. Dengan demikian, meski performa awal sangat menjanjikan, penelitian ini memerlukan perluasan data dan validasi eksternal untuk memastikan kesiapan penerapan klinis.

5.2 Saran

1. Perluasan Dataset dan Cross-Validation

Tambahkan data MRI dari pusat medis lain atau dataset publik tambahan untuk meningkatkan keragaman dan lakukan validasi silang (k-fold cross-validation) guna memastikan kestabilan performa di berbagai kondisi.

2. Eksperimen Multi-Kelas & Multi-Modal

Kembangkan model untuk membedakan tipe tumor berdasarkan histologi atau tingkat keganasan, dan pertimbangkan integrasi data

multimodal (CT, PET, atau metadata pasien) untuk meningkatkan akurasi diagnosis.

3. Validasi Eksternal dan Uji Klinis

Lakukan pengujian pada dataset eksternal dan studi prospektif di lingkungan klinis untuk menilai kinerja operasional, memperhitungkan variabilitas gambar dan protokol berbeda.

4. Peningkatan Interpretabilitas

Implementasikan teknik explainable AI (misalnya Grad-CAM atau integrated gradients) untuk memvisualisasikan area citra yang menjadi fokus model, sehingga hasil diagnosis dapat lebih mudah dipahami dan dipertanggungjawabkan oleh tenaga medis.

5. Optimasi Preprocessing & Augmentasi

Eksplorasi teknik augmentasi lanjutan (misalnya elastik, contrast adjustment) dan metode normalisasi adaptif untuk menambah robustness model terhadap noise dan artefak citra MRI.

REFERENSI

- [1] [1] K. S. D. Irmanti, D. M. Dama, dan T. Hidayat, “Analisis Komparatif Metode Peningkatan Kualitas Citra Digital untuk Deteksi Area Tubercoluma pada Citra MRI,” *J. J-Innovation*, vol. 13, no. 2, hlm. 71–77, Des. 2025. <https://doi.org/10.55600/jipa.v13i2.289>
- [2] P. Laksono, Harliana, dan T. Prabowo, “Deteksi Tumor Otak Melalui Penerapan GLCM dan Naïve Bayes Classification,” *J. Ilmiah Intech: Information Technology Journal of UMUS*, vol. 41, no. 48, hlm. 41–48, Mei 2023. <https://doi.org/10.46772/intech.v5i1.1286>
- [3] Jordie Sinulingga, D. R. Manalu, dan S. Manurung, “Klasifikasi Jenis Tumor Otak Berdasarkan Citra Glioma Menggunakan Metode Support Vector Machine,” *J. METHODIKA*, vol. 9, no. 2, hlm. 23–30, Sept. 2023. <https://doi.org/10.46880/mtk.v9i2.1887>
- [4] B. A. Ilham Aulia dan Alamsyah, “Peningkatan Hiperparameter Framework Deep Learning VGG-16 untuk Pendeteksian Tumor Otak pada Teknologi MRI,” *Indones. J. Math. Nat. Sci.*, vol. 47, no. 2, hlm. 99–107, 2024. <https://journal.unnes.ac.id/journals/JM/article/view/15116>
- [5] S. E. Dwi Bernadetta Sri Endah dan De Rosal Ignatius Moses Setiadi, “Deteksi Tumor Otak dengan Metode Convolutional Neural Network,” *J. Eksplora Informatika*, vol. 13, no. 2, hlm. 188–197, Nov. 2023. <https://doi.org/10.30864/eksplora.v13i2.971>
- [6] Siswoyo Azhar, D. Pratama, K. Anam, dan H. Susana, “Penerapan Algoritma Convolutional Neural Network (CNN) untuk Diagnosa Tumor Otak,” *JATI (Jurnal Mahasiswa Teknik Informatika)*, vol. 8, no. 2, hlm. 1797–1805, Apr. 2024. <https://doi.org/10.36040/jati.v8i2.8242>
- [7] Prayogi, A. C. Siregar, dan R. W. Saleh Insani, “Deteksi Tumor Otak Menggunakan Metode Watershed dan Thresholding pada Citra MRI,” *Jutisi: Jurnal Ilmiah Teknik Informatika dan Sistem Informasi*, vol. 12, no. 3, hlm. 1761–1766, Des. 2023. <http://dx.doi.org/10.35889/jutisi.v12i3.1688>

- [8] N. Nafisa, E. N. D. Br Purba, F. A. A. Harahap, dan N. A. Putri, “Implementasi Algoritma CNN Arsitektur Model MobileNetV2 dalam Klasifikasi Penyakit Tumor Otak Glioma, Pituitary dan Meningioma,” *Jurnal Teknologi Informasi, Komputer dan Aplikasinya (JTIKA)*, vol. 5, no. 1, hlm. 61–69, Mar. 2023. <https://doi.org/10.29303/jtika.v5i1.234>
- [9] R. Satila Passa, S. Nurmaini, dan D. P. Rini, “Deteksi Tumor Otak pada Magnetic Resonance Imaging Menggunakan YOLOv7,” *J. Ilmiah MATRIK*, vol. 25, no. 2, hlm. 116–124, Agt. 2023. <https://doi.org/10.33557/jurnalmatrik.v25i2.2404>
- [10] O. Akbar, E. Utami, dan D. Ariatmanto, “Deteksi Tumor Otak Melalui Gambar MRI Berdasarkan Vision Transformers dengan Tensorflow dan Keras,” *Jurnal Informatika Universitas Pamulang*, vol. 8, no. 3, hlm. 385–392, Sep. 2023, <https://doi.org/10.32493/informatika.v8i3.32707>

LAMPIRAN